


Päätöspuut



datavirtojen

louhinnassa

Toni Rämö, 20.12.2022



PÄÄTÖSPUU (Decision tree, DT)




PÄÄTÖSPUU

sää	x			y
	lämpötila (°C)	kosteus (%)	tuulista?	luokka
	24	70	tos	Pelaa
	27	90	tos	Älä pelaa
	29	85	epätosi	Älä pelaa
	22	95	epätosi	Älä pelaa
	21	70	epätosi	Pelaa
	22	90	tos	Pelaa
	28	78	epätosi	Pelaa
	18	65	tos	Pelaa
	27	75	epätosi	Pelaa
	22	80	tos	Älä pelaa
	18	70	tos	Älä pelaa
	24	80	epätosi	Pelaa
	20	80	epätosi	Pelaa
	21	96	epätosi	Pelaa

PÄÄTÖSPUU


x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tosi	Älä pelaa
☁☔	18	70	tosi	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa



PÄÄTÖSPUU


x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa

Jakokriteeri



PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätos	Älä pelaa
☀	22	95	epätos	Älä pelaa
☀	21	70	epätos	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätos	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätos	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätos	Pelaa
☁☔	20	80	epätos	Pelaa
☁☔	21	96	epätos	Pelaa



PÄÄTÖSPUU

sää	x			y
	lämpötila (°C)	kosteus (%)	tuulista?	luokka
	24	70	tosi	Pelaa
	27	90	tosi	Älä pelaa
	29	85	epätosi	Älä pelaa
	22	95	epätosi	Älä pelaa
	21	70	epätosi	Pelaa
	22	90	tosi	Pelaa
	28	78	epätosi	Pelaa
	18	65	tosi	Pelaa
	27	75	epätosi	Pelaa
	22	80	tosi	Älä pelaa
	18	70	tosi	Älä pelaa
	24	80	epätosi	Pelaa
	20	80	epätosi	Pelaa
	21	96	epätosi	Pelaa

sää

PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁🌧	22	80	tosi	Älä pelaa
☁🌧	18	70	tosi	Älä pelaa
☁🌧	24	80	epätosi	Pelaa
☁🌧	20	80	epätosi	Pelaa
☁🌧	21	96	epätosi	Pelaa




PÄÄTÖSPUU

sää	x			y
	lämpötila (°C)	kosteus (%)	tuulista?	luokka
	24	70	tos	Pelaa
	27	90	tos	Älä pelaa
	29	85	epätosi	Älä pelaa
	22	95	epätosi	Älä pelaa
	21	70	epätosi	Pelaa
	22	90	tos	Pelaa
	28	78	epätosi	Pelaa
	18	65	tos	Pelaa
	27	75	epätosi	Pelaa
	22	80	tos	Älä pelaa
	18	70	tos	Älä pelaa
	24	80	epätosi	Pelaa
	20	80	epätosi	Pelaa
	21	96	epätosi	Pelaa




PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁🌧	22	80	tosi	Älä pelaa
☁🌧	18	70	tosi	Älä pelaa
☁🌧	24	80	epätosi	Pelaa
☁🌧	20	80	epätosi	Pelaa
☁🌧	21	96	epätosi	Pelaa




PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
	24	70	tosi	Pelaa
	27	90	tosi	Älä pelaa
	29	85	epätosi	Älä pelaa
	22	95	epätosi	Älä pelaa
	21	70	epätosi	Pelaa
	22	90	tosi	Pelaa
	28	78	epätosi	Pelaa
	18	65	tosi	Pelaa
	27	75	epätosi	Pelaa
	22	80	tosi	Älä pelaa
	18	70	tosi	Älä pelaa
	24	80	epätosi	Pelaa
	20	80	epätosi	Pelaa
	21	96	epätosi	Pelaa



PÄÄTÖSPUU


sää	x			y
	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tosi	Älä pelaa
☁☔	18	70	tosi	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa



PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tosi	Älä pelaa
☁☔	18	70	tosi	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa


kosteus (%) ▼	luokka
70	Pelaa
70	Pelaa
85	Älä pelaa
90	Älä pelaa
95	Älä pelaa



PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa


kosteus (%) ▼	luokka
70	Pelaa
70	Pelaa
85	Älä pelaa
90	Älä pelaa
95	Älä pelaa



PÄÄTÖSPUU


x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa

kosteus (%) ▼	luokka
70	Pelaa
70	Pelaa
85	Älä pelaa
90	Älä pelaa
95	Älä pelaa




PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁🌧	22	80	tosi	Älä pelaa
☁🌧	18	70	tosi	Älä pelaa
☁🌧	24	80	epätosi	Pelaa
☁🌧	20	80	epätosi	Pelaa
☁🌧	21	96	epätosi	Pelaa




PÄÄTÖSPUU

x			y	
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätos	Älä pelaa
☀	22	95	epätos	Älä pelaa
☀	21	70	epätos	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätos	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätos	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätos	Pelaa
☁☔	20	80	epätos	Pelaa
☁☔	21	96	epätos	Pelaa




PÄÄTÖSPUU

x			y	
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätos	Älä pelaa
☀	22	95	epätos	Älä pelaa
☀	21	70	epätos	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätos	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätos	Pelaa
☁🌧	22	80	tos	Älä pelaa
☁🌧	18	70	tos	Älä pelaa
☁🌧	24	80	epätos	Pelaa
☁🌧	20	80	epätos	Pelaa
☁🌧	21	96	epätos	Pelaa




PÄÄTÖSPUU

x			y	
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätos	Älä pelaa
☀	22	95	epätos	Älä pelaa
☀	21	70	epätos	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätos	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätos	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätos	Pelaa
☁☔	20	80	epätos	Pelaa
☁☔	21	96	epätos	Pelaa



PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
	24	70	tos	Pelaa
	27	90	tos	Älä pelaa
	29	85	epätos	Älä pelaa
	22	95	epätos	Älä pelaa
	21	70	epätos	Pelaa
	22	90	tos	Pelaa
	28	78	epätos	Pelaa
	18	65	tos	Pelaa
	27	75	epätos	Pelaa
	22	80	tos	Älä pelaa
	18	70	tos	Älä pelaa
	24	80	epätos	Pelaa
	20	80	epätos	Pelaa
	21	96	epätos	Pelaa




PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀️	24	70	tosi	Pelaa
☀️	27	90	tosi	Älä pelaa
☀️	29	85	epätosi	Älä pelaa
☀️	22	95	epätosi	Älä pelaa
☀️	21	70	epätosi	Pelaa
☁️	22	90	tosi	Pelaa
☁️	28	78	epätosi	Pelaa
☁️	18	65	tosi	Pelaa
☁️	27	75	epätosi	Pelaa
☔️	22	80	tosi	Älä pelaa
☔️	18	70	tosi	Älä pelaa
☔️	24	80	epätosi	Pelaa
☔️	20	80	epätosi	Pelaa
☔️	21	96	epätosi	Pelaa

Syöte:

$x = (\text{☀️}, 24^\circ\text{C}, 50\%, \text{epätosi})$



PÄÄTÖSPUU


x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätosi	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätosi	Pelaa
☁☔	20	80	epätosi	Pelaa
☁☔	21	96	epätosi	Pelaa

Syöte:

$\mathbf{x} = (\text{☀}, 24^\circ\text{C}, 50\%, \text{epätosi})$

Ennuste:

$\text{DT}(\mathbf{x}) = \text{Pelaa}$




PÄÄTÖSPUU

x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tosi	Pelaa
☀	27	90	tosi	Älä pelaa
☀	29	85	epätosi	Älä pelaa
☀	22	95	epätosi	Älä pelaa
☀	21	70	epätosi	Pelaa
☁	22	90	tosi	Pelaa
☁	28	78	epätosi	Pelaa
☁	18	65	tosi	Pelaa
☁	27	75	epätosi	Pelaa
☁🌧	22	80	tosi	Älä pelaa
☁🌧	18	70	tosi	Älä pelaa
☁🌧	24	80	epätosi	Pelaa
☁🌧	20	80	epätosi	Pelaa
☁🌧	21	96	epätosi	Pelaa

Syöte:

$x = (\text{☁🌧}, 18^\circ\text{C}, 90\%, \text{tosi})$



PÄÄTÖSPUU


x				y
sää	lämpötila (°C)	kosteus (%)	tuulista?	luokka
☀	24	70	tos	Pelaa
☀	27	90	tos	Älä pelaa
☀	29	85	epätos	Älä pelaa
☀	22	95	epätos	Älä pelaa
☀	21	70	epätos	Pelaa
☁	22	90	tos	Pelaa
☁	28	78	epätos	Pelaa
☁	18	65	tos	Pelaa
☁	27	75	epätos	Pelaa
☁☔	22	80	tos	Älä pelaa
☁☔	18	70	tos	Älä pelaa
☁☔	24	80	epätos	Pelaa
☁☔	20	80	epätos	Pelaa
☁☔	21	96	epätos	Pelaa

Syöte:

$\mathbf{x} = (\text{☁☔}, 18^\circ\text{C}, 90\%, \text{tos})$

Ennuste:

$\text{DT}(\mathbf{x}) = \text{Älä pelaa}$




DATAVIRTOJEN LUOKITTELU




opetusnäytteiden virta




DATAVIRTOJEN LUOKITTELU



DATAVIRTOJEN LUOKITTELU



ALGORITMIT: Hoeffding-puu



HoeffdingPuu(S , X , G , δ)

```
01 /* Puun alustaminen */
02 Olkoon  $HT$  puu, joka koostuu yhdestä lehdestä  $L_1$  (puun juuri).
03 Olkoon  $X_1 = X \cup \{X_\emptyset\}$ .
04 Olkoon  $\bar{G}_1(X_\emptyset)$   $\bar{G}$ , joka saadaan ennustamalla yleisin luokka  $S$ :ssä.
05 Jokaiselle luokalle  $y_k$ :
06   Jokaisen luokan  $X_i \in X$  arvolla  $x_{ij}$ :
07     Olkoon  $n_{ijk}(L_1) = 0$ .

08 /* Oppiminen näyte kerrallaan */
09 Jokaiselle näytteelle  $(x, y_k)$   $S$ :ssä:
10   Luokittele näyte lehteen  $L$ .
11   Jokaisella  $x_{ij}$   $x$ :ssä, jolla  $X_i \in X$ :
12     Kasvata  $n_{ijk}(L)$ .
13   Valitse  $L$  tunnisteeksi luokka, josta on eniten havaintoja  $L$ :ssä.
14   Jos kaikki  $L$ :ssä havaitut näytteet eivät kuulu samaan luokkaan:
15     Laske  $\bar{G}_L(X_i)$  jokaiselle piirteelle  $X_i \in X_L - \{X_\emptyset\}$  tunnusluvulla  $n_{ijk}(L)$ .
16     Olkoon  $X_a$  piirre, jolla saadaan suurin  $\bar{G}_L$ .
17     Olkoon  $X_b$  piirre, jolla saadaan toiseksi suurin  $\bar{G}_L$ .
18     Laske  $\varepsilon$ .
19     Jos  $\bar{G}(X_a) - \bar{G}(X_b) > \varepsilon$  ja  $X_a \neq X_\emptyset$ :
20       Korvaa  $L$  testisolmulla, joka jakaa puun piirteen  $X_a$  mukaan.
21       Jokaiselle jaon haaralle:
22         Lisää uusi lehti  $L_m$  ja  $X_m = X - \{X_a\}$ .
23         Jokaisella luokalla  $y_k$  ja piirteen  $X_i \in X_m - X_\emptyset$  arvolla  $x_{ij}$ :
24           Olkoon  $n_{ijk}(L_m) = 0$ .
```

25 Palauta HT .

Syötteet

S näytteiden sarja
 X diskreettien piirteiden joukko
 $G(.)$ hyvyysfunktio
 δ 1-P(valitaan oikea piirre)

HoeffdingPuu(S , X , G , δ)

```
01 /* Puun alustaminen */
02 Olkoon  $HT$  puu, joka koostuu yhdestä lehdestä  $L_1$  (puun juuri).
03 Olkoon  $X_1 = X \cup \{X_\varnothing\}$ .
04 Olkoon  $\bar{G}_1(X_\varnothing)$   $\bar{G}$ , joka saadaan ennustamalla yleisin luokka  $S$ :ssä.
05 Jokaiselle luokalle  $y_k$ :
06   Jokaisen luokan  $X_i \in X$  arvolla  $x_{ij}$ :
07     Olkoon  $n_{ijk}(L_1) = 0$ .
```

```
08 /* Oppiminen näyte kerrallaan */
```

```
09 Jokaiselle näytteelle  $(x, y_k)$   $S$ :ssä:
10   Luokittele näyte lehteen  $L$ .
11   Jokaisella  $x_{ij}$   $x$ :ssä, jolla  $X_i \in X$ :
12     Kasvata  $n_{ijk}(L)$ .
13   Valitse  $L$  tunnisteeksi luokka, josta on eniten havaintoja  $L$ :ssä.
14   Jos kaikki  $L$ :ssä havaitut näytteet eivät kuulu samaan luokkaan:
15     Laske  $\bar{G}_L(X_i)$  jokaiselle piirteelle  $X_i \in X_L - \{X_\varnothing\}$  tunnusluvulla  $n_{ijk}(L)$ .
16     Olkoon  $X_a$  piirre, jolla saadaan suurin  $\bar{G}_L$ .
17     Olkoon  $X_b$  piirre, jolla saadaan toiseksi suurin  $\bar{G}_L$ .
18     Laske  $\varepsilon$ .
19     Jos  $\bar{G}(X_a) - \bar{G}(X_b) > \varepsilon$  ja  $X_a \neq X_\varnothing$ :
20       Korvaa  $L$  testisolmulla, joka jakaa puun piirteen  $X_a$  mukaan.
21       Jokaiselle jaon haaralle:
22         Lisää uusi lehti  $L_m$  ja  $X_m = X - \{X_a\}$ .
23         Jokaisella luokalla  $y_k$  ja piirteen  $X_i \in X_m - X_\varnothing$  arvolla  $x_{ij}$ :
24           Olkoon  $n_{ijk}(L_m) = 0$ .
```

```
25 Palauta  $HT$ .
```

Syötteet

S näytteiden sarja
 X diskreettien piirteiden joukko
 $G(\cdot)$ hyvyysfunktio
 δ 1-P(valitaan oikea piirre)

Oppiminen Hoeffding-puulla

1. Poimi näyte.
2. Luokittele näyte.
3. Päivitä lehden tunnusluvut.
4. Päivitä lehden luokkatunniste.
5. Tarkista **pysähtymiskriteeri** ja jatka, jos kriteeri ei täyty.
6. Laske **jakokriteerin** arviointiin tarvittavat lukuarvot.
7. Tarkista **jakokriteeri**.
8. Haarauta puu solmun kohdalta parhaalla piirteellä.
9. Alusta solmujen tunnusluvut.

	Hoeffding-puu (ja VFDT)
Jakokriteeri	$\Delta \bar{G} > \epsilon$, jossa $\Delta \bar{G} = \bar{G}(X_a) - \bar{G}(X_b)$ ja $X_a \neq X_\emptyset$ (VFDT:ssä $\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$)
Ylläpidettävät tiedot	Tunnusluvut lehdistä
Erityispiirteet	- Kasvattaa puuta asteittain - Puuta voi käyttää milloin vain (VFDT:ssä lisäksi mm. parametri τ, jolla hallitaan "tasapelejä")
Vaativuudet	
Aika	$O(1dvc)$ $O(dvc)$
	1 = lehtien määrä d = piirteiden määrä v = max arvojen määrä per piirre c = luokkien määrä
	(Domingos ja Hulten, 2000)

	Hoeffding-puu (ja VFDT)	Konseptimukautuva VFDT (CVFDT)
Jakokriteeri	$\Delta \bar{G} > \varepsilon$, jossa $\Delta \bar{G} = \bar{G}(X_a) - \bar{G}(X_b)$ ja $X_a \neq X_b$ (VFDT:ssä $\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$)	$\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$
Ylläpidettävät tiedot	♦ Tunnusluvut lehdistä	♦ Tunnusluvut kaikissa solmuissa ♦ Vaihtoehtoiset alipuut ♦ Ikkunaan kuuluvat näytteet
Erityispiirteet	♦ Kasvattaa puuta asteittain ♦ Puuta voi käyttää milloin vain ♦ (VFDT:ssä lisäksi mm. parametri τ, jolla hallitaan "tasapelejä")	+ Kasvattaa ja ylläpitää vaihtoehtoisia alipuita ja korvaa käytössä olevan alipuun, tarkkuustestin perusteella → <i>konseptimukautuvuus</i>
Vaativuudet		
Tila	$O(\mathbf{1} \text{ dvc})$	$O(\mathbf{n_c} \text{ dvc})$
Aika	$O(\text{ dvc})$	$O(\mathbf{h_c} \text{ dvc})$
	$\mathbf{1}$ = lehtien määrä $\mathbf{d}$ = piirteiden määrä $\mathbf{v}$ = max arvojen määrä per piirre $\mathbf{c}$ = luokkien määrä	$\mathbf{n_c}$ = kaikkien solmujen määrä $\mathbf{h_c}$ = puun korkeus kertaa vaihtoehtoisten alipuiden määrä
	(Domingos ja Hulten, 2000)	(Hulten et al., 2001)

	Hoeffding-puu (ja VFDT)	Konseptimukautuva VFDT (CVFDT)	Epävarmuutta käsittävä CVFDT
Jakokriteeri	$\Delta \bar{G} > \epsilon$, jossa $\Delta \bar{G} = \bar{G}(X_a) - \bar{G}(X_b)$ ja $X_a \neq X_b$ (VFDT:ssä $\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$)	$\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$	$\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$
Ylläpidettävät tiedot	♦ Tunnusluvut lehdissä	♦ Tunnusluvut kaikissa solmuissa ♦ Vaihtoehtoiset alipuut ♦ Ikunaan kuuluvat näytteet	♦ Kuten CVFDT
Erityis- piirteet	♦ Kasvattaa puuta asteittain ♦ Puuta voi käyttää milloin vain ♦ (VFDT:ssä lisäksi mm. parametri τ, jolla hallitaan "tasapelejä")	+ Kasvattaa ja ylläpitää vaihtoehtoisia alipuita ja korvaa käytössä olevan alipuun, tarkkuustestin perusteella → <i>konseptimukautuvuus</i>	+ Vaihtoehtoiset alipuut kuten CVFDT:ssä + Näytteet annetaan <i>todennäköisyysjakaumina</i>, jotka algoritmi pilkkoo osanäytteiksi
Vaativuudet			
Tila	$O(\mathbf{l} \text{ dvc})$	$O(\mathbf{n_c} \text{ dvc})$	$O(\mathbf{n_u} \text{ dvc})$
Aika	$O(\text{ dvc})$	$O(\mathbf{h_c} \text{ dvc})$	$O(\mathbf{n_u} \text{ dvc})$
	$\mathbf{l}$ = lehtien määrä $\mathbf{d}$ = piirteiden määrä $\mathbf{v}$ = max arvojen määrä per piirre $\mathbf{c}$ = luokkien määrä	$\mathbf{n_c}$ = kaikkien solmujen määrä $\mathbf{h_c}$ = puun korkeus kertaa vaihtoehtoisten alipuiden määrä	$\mathbf{n_u}$ = kaikkien solmujen määrä
	(Domingos ja Hulten, 2000)	(Hulten et al., 2001)	(Liang et al., 2010)

	Hoeffding-puu (ja VFDT)	Konseptimukautuva VFDT (CVFDT)	Epävarmuutta käsittävä CVFDT	Tiukka VFDT
Jakokriteeri	$\Delta \bar{G} > \epsilon$, jossa $\Delta \bar{G} = \bar{G}(X_a) - \bar{G}(X_b)$ ja $X_a \neq X_b$ (VFDT:ssä $\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$)	$\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$	$\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$	$\Delta \bar{G} > \epsilon$ tai $\epsilon < \tau$ 1. Solmun oletettuun luokkaan liittyy riittävän pieni epävarmuus . 2. Kaikilla lehtisolmuilla tulee olla yhtenevä määrä alkioita . 3. Jakoon käytettävän piirteen on oltava ollut mahdollisimman epärelevantti aiemmissa jaoissa.
Ylläpidettävät tiedot	♦ Tunnusluvut lehdissä	♦ Tunnusluvut kaikissa solmuissa ♦ Vaihtoehtoiset alipuut ♦ Ikkunaan kuuluvat näytteet	♦ Kuten CVFDT	♦ Tunnusluvut lehdissä
Erityis-piirteet	♦ Kasvattaa puuta asteittain ♦ Puuta voi käyttää milloin vain ♦ (VFDT:ssä lisäksi mm. parametri τ, jolla hallitaan "tasapelejä")	+ Kasvattaa ja ylläpitää vaihtoehtoisia alipuita ja korvaa käytössä olevan alipuun, tarkkuustestin perusteella → <i>konseptimukautuvuus</i>	+ Vaihtoehtoiset alipuut kuten CVFDT:ssä + Näytteet annetaan <i>todennäköisyysjakaumina</i>, jotka algoritmi pilkkoo osanäytteiksi	+ Tiukempi jakokriteeri → kasvaa maltillisemmin → pienempi puu, joten <i>pienempi muistin käyttö</i>
Vaativuudet	$O(\mathbf{1}dvc)$	$O(\mathbf{n_c}dvc)$	$O(\mathbf{n_u}dvc)$	$O(\mathbf{1_s}dvc)$
Aika	$O(\quad dvc)$	$O(\mathbf{h_c}dvc)$	$O(\mathbf{n_u}dvc)$	$O(\quad dvc)$
	$\mathbf{1}$ = lehtien määrä $\mathbf{d}$ = piirteiden määrä $\mathbf{v}$ = max arvojen määrä per piirre $\mathbf{c}$ = luokkien määrä	$\mathbf{n_c}$ = kaikkien solmujen määrä $\mathbf{h_c}$ = puun korkeus kertaa vaihtoehtoisten alipuiden määrä	$\mathbf{n_u}$ = kaikkien solmujen määrä	$\mathbf{1_s}$ = kaikkien lehtien määrä
	(Domingos ja Hulten, 2000)	(Hulten et al., 2001)	(Liang et al., 2010)	(Turrisi da Costa et al., 2018)

	Hoeffding-puu (ja VFDT)	Konseptimukautuva VFDT (CVFDT)	Epävarmuutta käsittävä CVFDT	Tiukka VFDT	Hoeffding- ainavalmis-puu
Jakokriteeri	$\Delta \bar{G} > \varepsilon$, jossa $\Delta \bar{G} = \bar{G}(X_a) - \bar{G}(X_b)$ ja $X_a \neq X_\emptyset$ (VFDT:ssä $\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$)	$\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$	$\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$	$\Delta \bar{G} > \varepsilon$ tai $\varepsilon < \tau$ 1. Solmun oletettuun luokkaan liittyy riittävän pieni epävarmuus . 2. Kaikilla lehtisolmuilla tulee olla yhtenevä määrä alkioita . 3. Jakoon käytettävän piirteen on oltava ollut mahdollisimman epärelevantti aiemmissa jaoissa.	$\bar{G}(X_a) - \bar{G}(X_\emptyset) > \varepsilon$
Ylläpidettävät tiedot	♦ Tunnusluvut lehdissä	♦ Tunnusluvut kaikissa solmuissa ♦ Vaihtoehtoiset alipuut ♦ Ikkunaan kuuluvat näytteet	♦ Kuten CVFDT	♦ Tunnusluvut lehdissä	♦ Tunnusluvut kaikissa solmuissa
Erityis- piirteet	♦ Kasvattaa puuta asteittain ♦ Puuta voi käyttää milloin vain ♦ (VFDT:ssä lisäksi mm. parametri τ, jolla hallitaan "tasapelejä")	+ Kasvattaa ja ylläpitää vaihtoehtoisia alipuita ja korvaa käytössä olevan alipuun, tarkkuustestin perusteella → <i>konseptimukautuvuus</i>	+ Vaihtoehtoiset alipuut kuten CVFDT:ssä + Näytteet annetaan <i>todennäköisyysjakaumina</i>, jotka algoritmi pilkkoo osanäytteiksi	+ Tiukempi jakokriteeri → kasvaa maltillisemmin → pienempi puu, joten <i>pienempi muistin käyttö</i>	+ Löyhempi jakokriteeri → kasvaa nopeammin → <i>käyttökelpoinen puu nopeammin</i> + Käy läpi testisolmuja ja päivittää jakoja jälkikäteen
Vaativuudet					
Tila	$O(\mathbf{1} \text{ dvc})$	$O(\mathbf{n_c} \text{ dvc})$	$O(\mathbf{n_u} \text{ dvc})$	$O(\mathbf{1_s} \text{ dvc})$	$O(\mathbf{n_h} \text{ dvc})$
Aika	$O(\text{ dvc})$	$O(\mathbf{h_c} \text{ dvc})$	$O(\mathbf{n_u} \text{ dvc})$	$O(\text{ dvc})$	$O(\mathbf{h_h} \text{ dvc})$
	$\mathbf{1}$ = lehtien määrä $\mathbf{d}$ = piirteiden määrä $\mathbf{v}$ = max arvojen määrä per piirre $\mathbf{c}$ = luokkien määrä	$\mathbf{n_c}$ = kaikkien solmujen määrä $\mathbf{h_c}$ = puun korkeus kertaa vaihtoehtoisten alipuiden määrä	$\mathbf{n_u}$ = kaikkien solmujen määrä	$\mathbf{1_s}$ = kaikkien lehtien määrä	$\mathbf{n_h}$ = kaikkien solmujen määrä $\mathbf{h_h}$ = puun korkeus
	(Domingos ja Hulten, 2000)	(Hulten et al., 2001)	(Liang et al., 2010)	(Turrisi da Costa et al., 2018)	(Manapragada et al. 2018)

YHTEENVETO

Datavirtojen luokittelu

- tyypillisesti vaativampaa kuin yksittäisten otosten

Päätöspuut

- tehokkaita luokittimia
- soveltuvat datavirtojen luokitteluun **Hoeffding-puun** avulla

Hoeffding-puu

- kasvattaa puuta asteittain
- saavuttaa hyviä tarkkuuksia isoilla opetusaineistoilla
- useita variaatioita eri tarkoituksiin. Tässä käsiteltiin neljää erilaista.

Tarkasteltujen algoritmien

- *O-tilavaativuus* riippuu piirteistä ja luokista sekä puun koosta (sitä näytteiden määrästä).
- *O-aikavaativuus* riippuu piirteistä ja luokista, ja monimutkaisemmissa myös puun koosta (sitä näytteiden määrästä).

